

Sprint 3 - Challenge Locaweb 2026

DATA PROTECTION & INGESTION

GRUPO: Dataway | Turma: 1TSCPV

INTEGRANTES:

- Isabella Heder - RM561300
- João Victor Dalessio - RM561050
- Paulo Luchini - RM561477
- Angelo Rabello - RM561926
- Milena Barbosa - RM558913

Este documento apresenta as evidências e a documentação técnica da Sprint 3 do Challenge Locaweb 2026, referente à disciplina Data Protection & Ingestion.


Nesta sprint foi implementado:

- Pipeline orquestrado de ingestão (Apache Airflow)
- Data Warehouse analítico (PostgreSQL) em arquitetura Medallion
- Estratégia de Backup e Recuperação (full + incremental)
- Simulação de falha e recovery comprovado

A solução está totalmente containerizada via Podman, garantindo portabilidade e reprodutibilidade.

ARQUITETURA BASE:

Nós decidimos realizar essa Sprint com base na **arquitetura definida nas sprints anteriores**, visto que **não havia nenhum requisito específico de ferramenta**.



A arquitetura do PredictOps 360 foi organizada em 5 camadas, utilizando **Apache Airflow**, **PostgreSQL** e **Podman**, garantindo escalabilidade, rastreabilidade e aderência a práticas modernas de Data Engineering e ML.

1. Extração: conversão do Excel para CSV padronizado (UTF-8).
2. Ingestão: Airflow orquestra pipelines em Python com logs, retries e monitoramento.
3. Armazenamento (PostgreSQL – Medallion):
 - Bronze: dados brutos
 - Silver: dados tratados + engenharia de atributos
 - Gold: dados agregados para KPIs
4. Orquestração: Airflow como padrão de mercado, integrado à stack de ML.
5. Infraestrutura: Podman garante segurança (rootless) e ambiente open-source.

A solução segue o padrão Lakehouse, entregando dados confiáveis e prontos para BI e IA.

Estratégia de Backup e Recuperação do Ambiente de Dados

A estratégia de backup do PredictOps 360 foi desenhada para garantir a proteção contínua do ambiente analítico (PostgreSQL com arquitetura Medallion: Bronze, Silver e Gold) e suportar a continuidade da solução de AIOps proposta para a Locaweb, cuja missão é antecipar incidentes, monitorar tendências operacionais e disponibilizar dados confiáveis para tomada de decisão.

Considerando que o pipeline alimenta dashboards estratégicos, painéis operacionais, jornal de turno, alertas mobile e e-mails diários para gestores, qualquer indisponibilidade ou perda dos dados comprometeria diretamente a operação do NOC e a confiabilidade dos modelos preditivos. Por isso, foi adotada uma estratégia em camadas, combinando backup full + backup incremental, em conformidade com os requisitos mínimos do desafio.

Componentes da Estratégia:

Item	Definição adotada
Backup FULL	Dump físico completo via pg_dump (formato custom -Fc), contemplando todos os schemas (bronze, silver, gold) + dados + metadados.
Backup INCREMENTAL	Backup seletivo das tabelas de Silver e Gold (camadas mais voláteis, atualizadas pelo Airflow diariamente). Bronze é considerada imutável após a carga,

	dispensando incremental adicional.
Política de Retenção	• FULL: 30 dias online + 1 ano cold storage • INCREMENTAL: 7 dias online • Logs de execução: 90 dias
Periodicidade	• FULL: diário, às 02h00 (horário de menor carga operacional) • INCREMENTAL: a cada 6 horas (00h, 06h, 12h, 18h) • Logs de execução: retidos por 90 dias
Local de Armazenamento	• Primário: volume persistente do Podman (/backup) montado no host • Secundário (produção): Azure Blob Storage com replicação geo-redundante (GRS) • Estrutura: /backup/full, /backup/incremental, /backup/logs

A escolha do PostgreSQL pg_dump em formato custom (-F c) deve-se a quatro fatores:

1. RECUPERAÇÃO SELETIVA: o formato custom permite restaurar tabelas ou schemas específicos sem necessidade de recuperar todo o banco.
2. COMPRESSÃO NATIVA: o formato custom comprime os dados durante o dump, reduzindo o consumo de armazenamento.
3. INTEGRIDADE TRANSACIONAL: o pg_dump executa um snapshot consistente sem bloquear escritas, permitindo que a DAG do Airflow continue operando durante o backup.
4. COMPATIBILIDADE COM O CICLO DE VIDA DO DADO: a separação entre backup full (diário) e incremental (a cada 6h) está alinhada com o refresh dos dashboards do PredictOps 360, que possuem janelas de atualização que vão de 1 minuto (Painel Operacional) a 1 hora (Dashboard Estratégico).

Estratégia de Recovery e Reprocessamento (25 pontos)

Para evidenciar a eficácia da estratégia de recovery, foi simulado um cenário crítico: a perda completa da tabela silver.incidentes_tratados, que é a fonte de dados primária para todas as agregações da camada Gold (kpi_por_equipe, kpi_por_prioridade, incidentes_diaros) e, conseqüentemente, para os dashboards e alertas do PredictOps 360 [1].

Esse cenário representa falhas reais possíveis em ambientes produtivos, tais como:

- Drop acidental por erro humano
- Corrupção da tabela por falha de disco

- Bugs em scripts de manutenção
- Problemas como "Bancos do SQL em Recovery" [3] já documentados no histórico de incidentes da Locaweb

Simulação de falha:

```
predictops_dw=# -- SIMULAÇÃO DE FALHA: tabela Silver corrompida/deletada
SELECT COUNT(*) FROM silver.incidentes_tratados; -- Antes: ~122.543

DROP TABLE silver.incidentes_tratados CASCADE;

-- Validar a "destruição"
SELECT COUNT(*) FROM silver.incidentes_tratados; -- ERRO: relation does not exist
\q
count
-----
122543
(1 row)

DROP TABLE
ERROR:  relation "silver.incidentes_tratados" does not exist
LINE 1: SELECT COUNT(*) FROM silver.incidentes_tratados;
```

erro: relation "silver.incidentes_tratados" does not exist

Fazendo backup (resolvendo o erro):

```
C:\cases-data-science\desafio-incidentes-lw\predictops360-sprint3>podman exec postgres-dw ls /backup/full/
predictops_dw_FULL_20260529_195851.backup
predictops_dw_FULL_20260529_195908.backup
predictops_dw_FULL_20260529_195917.backup
predictops_dw_FULL_20260529_195947.backup

C:\cases-data-science\desafio-incidentes-lw\predictops360-sprint3>podman exec postgres-dw bash -c "pg_restore -U predictops -d predic
tops_dw -t incidentes_tratados -n silver -v /backup/full/predictops_dw_FULL_20260529_195851.backup"
pg_restore: connecting to database for restore
pg_restore: creating TABLE "silver.incidentes_tratados"
pg_restore: processing data for table "silver.incidentes_tratados"

C:\cases-data-science\desafio-incidentes-lw\predictops360-sprint3>podman exec -it postgres-dw psql -U predictops -d predictops_dw
psql (15.18 (Debian 15.18-1.pgdgl3+1))
Type "help" for help.

predictops_dw=# SELECT COUNT(*) FROM silver.incidentes_tratados; -- Deve voltar a ~122.543

SELECT numero, prioridade, status, kpi_violado
FROM silver.incidentes_tratados
LIMIT 5;
\q
count
-----
122543
(1 row)


  numero | prioridade | status      | kpi_violado
-----+-----+-----+-----
 INC8654273 | 3 - Média | Sem Intervenção | 0
 INC8654270 | 4 - Baixa | Sem Intervenção | 0
 INC8654264 | 4 - Baixa | Sem Intervenção | 0
 INC8654263 | 4 - Baixa | Sem Intervenção | 0
 INC8654262 | 4 - Baixa | Sem Intervenção | 0
(5 rows)
```

A arquitetura combina três mecanismos para garantir continuidade e disponibilidade dos dados:


1. **Idempotência:** cada execução recria a tabela antes de inserir dados, evitando duplicações.
2. **Recovery granular:** o `pg_restore` permite restaurar apenas partes específicas, reduzindo o tempo de recuperação.
3. **Retry automático (Airflow):** tasks com tentativas automáticas corrigem falhas transitórias sem intervenção manual.


Evidências (prints):

Evidência Postman:



Evidência Pipeline (DAG) Rodando:





Evidência de exploração da estrutura do Data Warehouse (schemas e tabelas):

```

\dn -- Listar schemas
\dt bronze.* -- Tabelas da bronze
\dt silver.* -- Tabelas da silver
\dt gold.* -- Tabelas da gold
\d silver.incidentes_tratados -- Estrutura da tabela
SELECT COUNT(*) FROM silver.incidentes_tratados;
\q

```

Table "silver.incidentes_tratados"				
Column	Type	Collation	Nullable	Default
numero	character varying(20)		not null	
prioridade	character varying(50)		not null	
produto	character varying(500)		not null	
categoria	character varying(500)		not null	
subcategoria	character varying(500)		not null	
grupo_designado	character varying(100)		not null	
item_configuracao	character varying(500)		not null	
aberto	timestamp without time zone		not null	
resolvido	timestamp without time zone		not null	
encerrado	timestamp without time zone		not null	
duracao	bigint		not null	
codigo_fechamento	character varying(500)		not null	
descricao_resumida	text		not null	
solucao	text		not null	
aberto_por	character varying(100)		not null	
incidente_pai	character varying(20)		not null	
status	character varying(50)		not null	
entrou_kpi	character varying(10)		not null	
kpi_violado_texto	character varying(20)		not null	
tem_resolucao	smallint		not null	
tem_pai	smallint		not null	
tem_produto	smallint		not null	
tem_categoria	smallint		not null	
tem_subcategoria	smallint		not null	
tem_item_config	smallint		not null	
tem_cf	smallint		not null	
kpi_violado	smallint		not null	
kpi_nao_aplicavel	smallint		not null	
dt_carga	timestamp without time zone			CURRENT_TIMESTAMP
nmn_usuario_carga	character varying(50)			CURRENT_USER
Indexes:				
"incidentes_tratados_pkey" PRIMARY KEY, btree (numero)				
"idx_silver_aberto" btree (aberto)				
"idx_silver_grupo" btree (grupo_designado)				
"idx_silver_prioridade" btree (prioridade)				
"idx_silver_status" btree (status)				

Evidência de SELECT (gold):

```
C:\Users\IsabellaHeder>podman exec -it postgres-dw psql -U predictops -d predictops_dw
psql (15.18 (Debian 15.18-1.pgdg13+1))
Type "help" for help.

predictops_dw=# SELECT COUNT(*) FROM gold.kpi_por_equipe;
SELECT COUNT(*) FROM gold.kpi_por_prioridade;
SELECT COUNT(*) FROM gold.incidentes_diarios;
SELECT * FROM gold.kpi_por_equipe ORDER BY total_violacoes DESC LIMIT 10;
\q
count
-----
3729
(1 row)

count
-----
1591
(1 row)

count
-----
644
(1 row)

grupo_designado | data_referencia | total_incidentes | total_violacoes | pct_violacao | duracao_media_seg
-----
Team14 | 2025-06-16 | 84 | 3 | 3.57 | 315270.38
Team11 | 2025-06-18 | 64 | 3 | 4.69 | 198567.73
Team11 | 2025-03-20 | 34 | 3 | 8.82 | 590309.65
Team11 | 2025-05-30 | 70 | 2 | 2.86 | 413617.06
Team07 | 2025-12-21 | 6 | 2 | 33.33 | 42261.67
Team05 | 2025-11-27 | 61 | 2 | 3.28 | 75125.64
Team11 | 2025-01-16 | 42 | 2 | 4.76 | 158932.33
Team11 | 2025-12-27 | 3 | 2 | 66.67 | 34431.33
Team11 | 2025-09-23 | 46 | 2 | 4.35 | 53149.24
Team11 | 2025-06-05 | 33 | 2 | 6.06 | 61617.91
(10 rows)
```

Evidência Backups Criados:

```
C:\cases-data-science\desafio-incidentes-lw\predictops360-sprint3>podman exec --user root postgres-dw bash /backup/backu
p_postgres.sh
BACKUP FULL iniciado em Fri May 29 07:59:47 PM UTC 2026
Backup FULL criado: predictops_dw_FULL_20260529_195947.backup (7.2M)
Backups com mais de 30 dias removidos
Backups disponiveis:
-rwxrwxrwx 1 root root 7.2M May 29 19:58 /backup/full/predictops_dw_FULL_20260529_195851.backup
-rwxrwxrwx 1 root root 7.2M May 29 19:59 /backup/full/predictops_dw_FULL_20260529_195908.backup
-rwxrwxrwx 1 root root 7.2M May 29 19:59 /backup/full/predictops_dw_FULL_20260529_195917.backup
-rwxrwxrwx 1 root root 7.2M May 29 19:59 /backup/full/predictops_dw_FULL_20260529_195947.backup
Processo concluido em Fri May 29 07:59:49 PM UTC 2026

C:\cases-data-science\desafio-incidentes-lw\predictops360-sprint3>podman exec --user root postgres-dw bash /backup/backu
p_incremental.sh
BACKUP INCREMENTAL iniciado em Fri May 29 08:00:01 PM UTC 2026
pg_dump: last built-in OID is 16383
pg_dump: reading extensions
pg_dump: identifying extension members
pg_dump: reading schemas
pg_dump: reading user-defined tables
pg_dump: reading user-defined functions
pg_dump: reading user-defined types
pg_dump: reading procedural languages
pg_dump: reading user-defined aggregate functions
pg_dump: reading user-defined operators
pg_dump: reading user-defined access methods
pg_dump: reading user-defined operator classes
pg_dump: reading user-defined operator families
pg_dump: reading user-defined text search parsers
pg_dump: reading user-defined text search templates
pg_dump: reading user-defined text search dictionaries
pg_dump: reading user-defined text search configurations
pg_dump: reading user-defined foreign-data wrappers
pg_dump: reading user-defined foreign servers
pg_dump: reading default privileges
pg_dump: reading user-defined collations
pg_dump: reading user-defined conversions
```

```
pg_dump: dumping contents of table "gold.incidentes_diarios"
pg_dump: dumping contents of table "gold.kpi_por_equipe"
pg_dump: dumping contents of table "gold.kpi_por_prioridade"
pg_dump: dumping contents of table "silver.incidentes_tratados"
Backup INCREMENTAL criado: predictops_dw_INC_20260529_200001.backup
```

LISTA DE BACKUPS:

```
C:\cases-data-science\desafio-incidentes-lw\predictops360-sprint3>podman exec postgres-dw ls -lh /backup/full/
total 29M
-rwxrwxrwx 1 root root 7.2M May 29 19:58 predictops_dw_FULL_20260529_195851.backup
-rwxrwxrwx 1 root root 7.2M May 29 19:59 predictops_dw_FULL_20260529_195908.backup
-rwxrwxrwx 1 root root 7.2M May 29 19:59 predictops_dw_FULL_20260529_195917.backup
-rwxrwxrwx 1 root root 7.2M May 29 19:59 predictops_dw_FULL_20260529_195947.backup

C:\cases-data-science\desafio-incidentes-lw\predictops360-sprint3>podman exec postgres-dw ls -lh /backup/incremental/
total 3.8M
-rwxrwxrwx 1 root root 3.8M May 29 20:00 predictops_dw_INC_20260529_200001.backup
```