

Sprint 3 – Challenge Locaweb 2026


Disciplina: Data Warehousing & Advanced Data Integration

GRUPO: Dataway | Turma: 1TSCPV

INTEGRANTES:

- Isabella Heder - RM561300
- João Victor Dalessio - RM561050
- Paulo Luchini - RM561477
- Angelo Rabello - RM561926
- Milena Barbosa - RM558913

1. ARQUITETURA DA SOLUÇÃO



A arquitetura proposta para a Sprint 3 do Challenge Locaweb implementa um pipeline completo de ingestão, transformação e persistência de dados utilizando recursos PaaS (Platform as a Service) do Microsoft Azure, organizados em um Resource Group único na região Brazil South.

O fluxo se inicia com uma camada de **pré-processamento local** executada em ambiente Python (notebook Jupyter), responsável por: (i) converter o arquivo original **LW-DATASET.xlsx** (fornecido pela Locaweb) para o formato CSV padronizado com encoding UTF-8-sig e separador ponto-e-vírgula, (ii) gerar uma tabela dimensional **dim_prioridade.xlsx** com informações sobre níveis de criticidade, SLAs em horas e cores para dashboard e (iii) extrair e classificar os grupos designados em um arquivo **dim_grupos.txt**, categorizando-os por área de responsabilidade (Infraestrutura, Aplicação ou Negócio). Essa etapa garante a padronização dos dados e a criação de dimensões de enriquecimento que serão utilizadas posteriormente no JOIN realizado dentro

do Data Factory. Após o pré-processamento, os três arquivos resultantes são carregados manualmente para o Azure Blob Storage.

O fluxo da Azure é dividido em três camadas principais:


- (1) Camada de Origem: três arquivos heterogêneos (CSV, XLSX e TXT) armazenados no Azure Blob Storage, representando os dados brutos do ServiceNow e duas dimensões de enriquecimento (prioridade e grupos);
- (2) Camada de Transformação: orquestrada pelo Azure Data Factory por meio de um Pipeline que executa um Data Flow contendo Sources, JOIN, Derived Columns (com mais de 18 expressões de transformação), Select e múltiplos Sinks;
- (3) Camada de Destino: persistência paralela em dois destinos — Azure SQL Database (banco analítico estruturado) e arquivo TXT no Blob Storage (backup auditável), atendendo ao requisito de múltipla persistência.

Esta arquitetura garante escalabilidade (processamento distribuído), rastreabilidade (via colunas DT_CARGA e NMN_USUARIO_CARGA) e abre caminho para integrações futuras com ferramentas de visualização e análise como o Power BI.

2. EVIDÊNCIAS DA INFRAESTRUTURA PaaS

Para a execução do Challenge, foram provisionados quatro recursos PaaS no portal Azure, todos agrupados no Resource Group "rg-challenge-locaweb-sprint3" na região Brazil South.

Resource Group com todos os recursos:



O Resource Group concentra todos os recursos do projeto, facilitando o gerenciamento, controle de custos e o desligamento posterior do ambiente. Contém: Storage Account, SQL Server, SQL Database e Data Factory.

Storage Account + containers:

Name	Last modified	Anonymous access level	Lease state	Storage connector
\$logs	29/05/2026, 10:26:46	Private	Available	-
processed	29/05/2026, 10:27:41	Private	Available	-
raw-data	29/05/2026, 10:27:29	Private	Available	-

Arquivos dentro do container raw:

Microsoft Azure

Home > stchallengeolocaweb_1780061073039 | Overview > stchallengeolocaweb | Containers

raw-data

Container

Search

+ Add Directory Upload Change access level Refresh Delete Copy Paste Rename Acquire lease Break lease Edit columns

Overview

Diagnose and solve problems

Access Control (IAM)

Settings

raw-data

Authentication method: Access key (Switch to Microsoft Entra user account)

Add filter

Search blobs by prefix (case-sensitive)

Only show active blobs

Showing all 3 items

☐	Name	Last modified	Access tier	Blob type	Size	Lease state
☐	dim_grupos.txt	29/05/2026, 10:30:26	Hot (Inferred)	Block blob	306 B	Available
☐	dim_prioridade.xlsx	29/05/2026, 10:29:32	Hot (Inferred)	Block blob	5.04 KiB	Available
☐	incidentes_para_adf.csv	29/05/2026, 10:29:47	Hot (Inferred)	Block blob	22.62 MiB	Available

O Storage Account foi configurado com dois containers privados: "raw-data" (que armazena os três arquivos de origem do pipeline: incidentes.csv, dim_prioridade.xlsx e dim_grupos.txt) e "processed" (destinado a receber o arquivo TXT consolidado após o processamento).

SQL SERVER

Microsoft Azure

Home > Microsoft.SqlServer.createServer_4c531cbb2161476b82ae42647802de6 | Overview

srv-challenge-locaweb

SQL server

Ensure disaster recovery readiness Optimize MAXDOP configuration Analyze query performance bottlenecks

Search

Create database New elastic pool New dedicated SQL pool (formerly SQL DW) Import database Reset password Move Delete Feedback

Overview

Activity log

Access control (IAM)

Tags

Quick start

Diagnose and solve problems

Resource visualizer

Settings

Data management

Essentials

Resource group (move): rg-challenge-locaweb-sprint3

Status: Available

Location: Brazil South

Subscription (move): Azure for Students

Subscription ID: effd9435-5553-4031-a33c-fcfe15e39273

Tags (edit): Add tags

Server admin: adminchallenge

Networking: Show networking settings

Microsoft Entra admin: Not configured

Server name: srv-challenge-locaweb.database.windows.net

Notifications (0) Features (6)

All Security (4) Performance (1) Recovery (1)

SQL DATABASE

Microsoft Azure

Home > Azure SQL | SQL databases > db-locaweb-incidentes (srv-challenge-locaweb/db-locaweb-incidentes)

Azure SQL | SQL databases

Grupo Alun

Search

Create Manage view

Overview

All resources

Azure SQL Database

SQL databases

Hyperscale databases

Elastic pools

SQL logical servers

Azure SQL Managed Instance

SQL Server

Related services

Help

db-locaweb-incidentes (srv-challenge-locaweb/db-locaweb-incidentes)

SQL database

Search

New query Templates Open in Feedback Sign out Classic experience

Overview

Activity log

Tags

Diagnose and solve problems

Query editor (preview)

Mirror database in Fabric (preview)

Resource visualizer

Settings

Data management

Integrations

Power Platform

Security

Intelligent performance

Monitoring

Automation

Help

Explorer

db-locaweb-incidentes

dbo

Queries

SQL query 1

SQL query 1

Run Save as view


1 SELECT GETDATE() AS data_atual;

Messages Results

data_atual

1 2026-05-29T13:47:21.5030000

ADF




O Azure SQL Database foi configurado no tier "Basic" (5 DTU), suficiente para os volumes do desafio. O firewall foi configurado para permitir conexões de serviços Azure (necessário para o ADF) e do IP do desenvolvedor (acesso ao Query Editor). A tabela "fato_incidentes" foi criada via script DDL antes da execução do pipeline.

3. DATA FLOW (ETL)

O Azure Data Factory atua como ferramenta central de orquestração ETL, abrigando os componentes responsáveis pelas conexões (Linked Services), representações dos dados (Datasets), regras de transformação (Data Flows) e fluxo de execução (Pipelines). Foram configurados dois Linked Services (um para o Blob Storage e outro para o Azure SQL Database), quatro Datasets (CSV, Excel, TXT e Tabela SQL) e um Data Flow contendo todas as transformações exigidas pelo desafio.

canvas do Data Flow completo:



O Data Flow é estruturado em seis etapas sequenciais:

(1) srcIncidentes — Source que lê o arquivo incidentes.csv do Blob Storage, contendo aproximadamente 122 mil registros de incidentes com 19 colunas originais.

(2) srcPrioridade — Source que lê a dimensão dim_prioridade.xlsx, trazendo metadados de criticidade, SLAs e cores para dashboard.

(3) joinPrioridade — Transformação JOIN do tipo Left Outer Join entre srcIncidentes e srcPrioridade, utilizando a coluna "Prioridade" como chave de junção. Essa etapa atende ao requisito de múltiplas origens com integração no ADF.

(4) derivedTransformacoes — Primeira transformação Derived Column, responsável pela maior parte do enriquecimento dos dados. Cria mais de 18 novas colunas, incluindo flags binárias (tem_resolucao, tem_pai, tem_produto, tem_categoria, tem_subcategoria, tem_item_config, tem_CF), tratamento de valores nulos (Resolvido, Produto, Categoria, Subcategoria, Item_Configuracao, Codigo_Fechamento, Solucao), classificação inteligente baseada em regras de negócio e colunas obrigatórias de auditoria (DT_CARGA com currentUTC() e NMN_USUARIO_CARGA com o RM do aluno).

(5) derivedFlags — Segunda transformação Derived Column, criando duas flags numéricas relacionadas ao indicador de KPI: kpi_violado (1 quando KPI Violado? = 'SIM', 0 caso contrário) e kpi_nao_aplicavel (1 quando o incidente não entrou para análise de KPI, 0 caso contrário).

(6) selectColunas — Transformação Select utilizada para limpar o schema final, removendo colunas duplicadas (versões com e sem acentos) e padronizando os nomes das colunas para o formato exigido pela tabela SQL de destino (sem espaços e sem caracteres especiais).

Derived Columns:

Derived column's settings Optimize Inspect Data preview ●

Columns ⓘ

☐	Column	Expression		
☐	tem_resolucao	iif(isNull(Resolvido), 0, 1)	123	+
☐	Resolvido	iifNull(Resolvido, Encerrado)		+
☐	tem_pai	iif(isNull((Incidente Pai)), 0, 1)	123	+
☐	tem_produto	iif(isNull(Produto), 0, 1)	123	+
☐	Produto	iif(isNull(Produto), iif((Aberto por)='Monitora...	abc	+
☐	tem_categoria	iif(isNull(Categoria), 0, 1)	123	+
☐	Categoria	iif(isNull(Categoria), iif(regexMatch(Produto,'*M...	abc	+
☐	tem_subcategoria	iif(isNull(Subcategoria), 0, 1)	123	+
☐	Subcategoria	iif(isNull(Subcategoria), concat(Categoria,'_Geral'...	abc	+
☐	tem_item_config	iif(isNull((Item de configuração)), 0, 1)	123	+
☐	Item_Configuracao	iifNull((Item de configuração), 'SEM_IC')	abc	+
☐	tem_CF	iif(isNull((Código de fechamento)) (Código de f...	123	+
☐	Codigo_Fechamento	iif(isNull((Código de fechamento)) upper((Cód...	abc	+
☐	Solucao	iif(isNull((Solução)), iif(Status='Sem Intervençã...	abc	+
☐	DT_CARGA	currentUTC()		+
☐	NMN_USUARIO_CARGA	'RM561300'	abc	+
☐	MES_ABERTURA	month(Aberto)	123	+
☐	ANO_ABERTURA	year(Aberto)	123	+

Columns * ⓘ

Column	Expression
kpi_violado	iif({KPI Violado?}=="SIM", 1, 0)
kpi_nao_aplicavel	iif({Entrou para KPI?}=="NAO", 1, 0)

Conforme exigência do desafio, todas as transformações de dados (padronização, limpeza, enriquecimento e criação de novas colunas) foram implementadas dentro do Azure Data Factory, em um Data Flow denominado "df_processa_incidentes". Este componente representa o coração do pipeline ETL.

A imagem acima ilustra exemplos das expressões nativas do ADF utilizadas, como iif(), iifNull(), isNull(), case(), instr(), concat(), upper(), year(), month() e currentUTC(). A lista completa das funções e suas regras está documentada no arquivo `colunas_derivadas.txt`, anexo a este projeto.

Conteúdo do `colunas_derivadas.txt` (incluso no `.docx`):

COLUNA	FUNÇÃO AZURE ADF
tem_resolucao	iif(isNull(Resolvido), 0, 1)
Resolvido	iifNull(Resolvido, Encerrado)
tem_pai	iif(isNull({Incidente Pai}), 0, 1)
tem_produto	iif(isNull(Produto), 0, 1)
Produto	iif(isNull(Produto), iif({Aberto por}=="Monitoramento",'MONITORING_AUTO','MANUAL_NAO_CLASSIFICADO'), Produto)
tem_categoria	iif(isNull(Categoria), 0, 1)
Categoria	iif(isNull(Categoria), iif(instr(Produto,'MONITORING')>0,'INFRA_Monitoramento','NAO_CLASSIFICADO_OUTROS'), Categoria)
tem_subcategoria	iif(isNull(Subcategoria), 0, 1)
Subcategoria	iif(isNull(Subcategoria), concat(Categoria,'_Geral'), Subcategoria)
tem_item_config	iif(isNull({Item de configuração}), 0, 1)
Item_Configuracao	iifNull({Item de configuração}, 'SEM_IC')
tem_CF	iif(isNull({Código de fechamento}) {Código de fechamento}=="Outro", 0, 1)
Codigo_Fechamento	iif(isNull({Código de fechamento}) upper({Código de fechamento})=="OUTRO", iif(Status=="Sem Intervenção",'AUTO_SEM_INTERVENCAO',iif(Status=="Encerrado Automaticamente",'AUTO_ENCERRADO','NAO_DOCUMENTADO')), {Código de fechamento})
Solucao	iif(isNull({Solução}), iif(Status=="Sem Intervenção",'SEM_SOLUCAO',iif(!isNull(Resolvido),'NAO_DOCUMENTADA','SEM_SOLUCAO')), {Solução})
kpi_violado	iif({KPI Violado?}=="SIM", 1, 0)
kpi_nao_aplicavel	iif({Entrou para KPI?}=="NAO", 1, 0)
ANO_ABERTURA	year(Aberto)
MES_ABERTURA	month(Aberto)
DT_CARGA	currentUTC()
NMN_USUARIO_CARGA	'RM561300'

DESCRIÇÃO:

Este arquivo contém todas as funções de transformação utilizadas dentro do Azure Data Factory para criar e enriquecer as colunas do dataset de incidentes da Locaweb. As funções foram aplicadas em uma transformação do tipo "Derived Column" no Data Flow df_processa_incidentes, permitindo padronizar valores nulos, criar flags binárias e adicionar colunas de auditoria (DT_CARGA, NMN_USUARIO_CARGA).

5. EVIDÊNCIAS DA EXECUÇÃO:

Pipeline executado com sucesso (Monitor):

The screenshot shows the 'Monitor' tab in the Azure Data Factory portal. The left sidebar contains navigation links: Home, Author, Monitor (selected), Manage, and Learning Center. The main area displays 'Pipeline runs' for the pipeline 'pl_ingestao_incidentes'. The 'Triggered' tab is active, showing a table of runs. The table has columns: Pipeline name, Run start, Run end, Duration, Triggered by, Status, and Run. One run is listed with a status of 'Succeeded'.

Pipeline name	Run start	Run end	Duration	Triggered by	Status	Run
pl_ingestao_incidentes	5/29/2026, 3:37:40 PM	5/29/2026, 3:44:01 PM	6m 21s	Manual trigger	Succeeded	Origir

SELECT COUNT(*) FROM fato_incidentes:

The screenshot shows the 'db-locaweb-incidentes' SQL database in the Azure Data Explorer. The 'New query' button is visible. The query editor shows the SQL query: 'SELECT COUNT(*) AS qtd_linhas FROM fato_incidentes;'. The 'Results' tab is active, displaying a table with one row and one column, 'qtd_linhas', with the value '0'.

qtd_linhas
0

SELECT TOP 10 mostrando dados:

db-locaweb-incidentes (srv-challenge-locaweb/db-locaweb-incident... SQL database

New query Templates Open in Feedback Sign out Classic experience

SQL query 2 SQL query 3 SQL query 4 SQL query 5

Run Save as view

```
1 -- Visualiza as primeiras 10 linhas
2 SELECT TOP 10 * FROM fato_incidentes;
```

Messages Results

	ABC Numero	ABC Prioridade	ABC Produto	ABC Categoria	ABC Subcateg...	ABC Grupo_D...	ABC Item_Con...	Aberto
1	INC8638187	3 - Média	MONITORING...	NAO_CLASSIF...	NULL	Team14	IC00131	2025-12-18T1
2	INC8638186	3 - Média	MONITORING...	NAO_CLASSIF...	NULL	Team14	IC00060	2025-12-18T1
3	INC8638185	4 - Baixa	MONITORING...	NAO_CLASSIF...	NULL	Team14	IC00032	2025-12-18T1
4	INC8638184	4 - Baixa	MONITORING...	NAO_CLASSIF...	NULL	Team14	IC00014	2025-12-18T1
5	INC8638183	3 - Média	Irev	cat97	sub437	Team14	IC01156	2025-12-18T1
6	INC8638182	3 - Média	MONITORING...	NAO_CLASSIF...	NULL	Team14	IC00570	2025-12-18T1
7	INC8638180	4 - Baixa	MONITORING...	NAO_CLASSIF...	NULL	Team14	IC00024	2025-12-18T1
8	INC8638179	3 - Média	MONITORING...	NAO_CLASSIF...	NULL	Team14	IC00153	2025-12-18T1
9	INC8638178	4 - Baixa	MONITORING...	NAO_CLASSIF...	NULL	Team14	IC00057	2025-12-18T1
10	INC8638177	4 - Baixa	MONITORING...	NAO_CLASSIF...	NULL	Team14	IC00511	2025-12-18T1

Testando:

db-locaweb-incidentes (srv-challenge-locaweb/db-locaweb-incident... SQL database

New query Templates Open in Feedback Sign out Classic experience

SQL query 3 SQL query 4 SQL query 5 SQL query 6


Run Save as view

```
1 -- Análise rápida: quantos incidentes por prioridade
2 SELECT
3     Prioridade,
4     COUNT(*) AS total,
5     SUM(kpi_violado) AS violacoes_kpi
6 FROM fato_incidentes
7 GROUP BY Prioridade
8 ORDER BY total DESC;
```

Messages Results

	ABC Prioridade	123 total	123 violacoes_kpi
1	4 - Baixa	64828	0
2	3 - Média	41732	206
3	2 - Alta	15649	42
4	5 - Muito Baixa	333	0
5	NULL	11	0
6	1 - Crítica	1	0

arquivo TXT no Blob Storage:



Criação de tabela fato no SQL Database:

ps: colocamos números altos nos VARCHARs porque ao rodarmos o pipeline (trigger) deu erro na questão de terem valores muito grandes que não caberiam no VARCHAR

```
-- TABELA: fato_incidentes
```

```
CREATE TABLE fato_incidentes (
```

```
-- Chaves e identificação
```

```
Numero VARCHAR(255) NOT NULL,
```

```
-- Atributos principais
```

```
Prioridade VARCHAR(100),
```

```
Produto VARCHAR(500),
```

```
Categoria VARCHAR(500),
```

```
Subcategoria VARCHAR(500),
```

```
Grupo_Designado VARCHAR(500),
```

```
Item_Configuracao VARCHAR(500),
```

```
-- Datas
```

```
Aberto DATETIME2,
```

```
Resolvido DATETIME2,
```

```
Encerrado DATETIME2,
```

```
-- Métricas
```

```
Duracao BIGINT,
```

```
-- Resolução / Solução
```

```
Codigo_Fechamento VARCHAR(500),
```

```
Descricao_Resumida NVARCHAR(MAX),
```

```
Solucao NVARCHAR(MAX),
```

```

Aberto_Por          VARCHAR(500) ,
Incidente_Pai       VARCHAR(255) ,
Status              VARCHAR(200) ,

-- KPI textual
Entrou_Para_KPI     VARCHAR(20) ,
KPI_Violado_Texto   VARCHAR(50) ,

-- Flags binárias (criadas no ADF)
tem_resolucao       INT ,
tem_pai             INT ,
tem_produto         INT ,
tem_categoria       INT ,
tem_subcategoria    INT ,
tem_item_config     INT ,
tem_CF              INT ,
kpi_violado         INT ,
kpi_nao_aplicavel   INT ,

-- Enriquecimento da dim_prioridade (vindo do JOIN)
SLA_Horas           INT ,
Criticidade_Nivel   VARCHAR(50) ,
Cor_Dashboard       VARCHAR(20) ,

-- Colunas derivadas adicionais
ANO_ABERTURA       INT ,
MES_ABERTURA       INT ,

-- Auditoria (obrigatórias do desafio)
DT_CARGA            DATETIME2 ,
NMN_USUARIO_CARGA   VARCHAR(50)
);

```