




ANTECIPE O FUTURO, PROTEJA O PRESENTE



INTEGRANTES

**Angelo
Rabello**

RM564338

**Isabella
Heder**

RM561300

**João
Daleggio**

RM561050



**Milena
Oliveira**

RM558913

**Paulo
Luchini**

RM561477





Proposta da Solução

Uma plataforma que responde três perguntas que a operação faz todo dia

1

Quanto vem?

Prevê a demanda futura de incidentes, permitindo planejamento proativo de equipes e recursos.

2

O que vai estourar?

Identifica riscos operacionais antes do impacto, prevenindo aumento de MTTR, degradação de KPIs e possíveis sobrecargas na operação.

3

Onde agir primeiro?

Prioriza ações com maior impacto operacional para apoiar a tomada de decisão.

Para quem?

Operadores & Analistas

Usuários da solução, acesso aos painéis para melhor organização e análise da situação

Gestores

Responsáveis pela gestão e pelo indicador de desempenho. A plataforma ajuda com decisões.

Clientes

Não utilizam a plataforma, mas são afetados pela qualidade da operação interna

Funcionalidades da Solução



PAINEL NOC

Painel operacional: Para monitoramento em tempo real de incidentes, OLAs e alertas críticos

Usuário: Operadores

JORNAL DE TURNO

Painel de turno: Para monitoramento dos incidentes, alertas e métricas durante o turno específico.

Usuário: Gestores e Operadores

PAINEL GERENCIAL

Painel de negócios: Para decisão estratégica baseada em incidentes, times, demandas e riscos.

Usuário: Gestores

CONSULTAS SQL

Linguagem Natural: Permite consultar a base histórica de incidentes em linguagem natural, convertendo perguntas em queries SQL

Usuário: Gestores e Operadores

CHATBOT

IA Assistente: Para esclarecer dúvidas em tempo real, investiga reincidências operacionais e orienta decisões com análises preditivas de OLA

Usuário: Gestores e Operadores



Motor analítico

São oito modelos publicados, agrupados pela pergunta de negócio que respondem

QUANTO VEM

Previsão da Demanda

- D+1 (dia seguinte)
- D+7 (semana seguinte)
- Por turno (4 janelas)
- Por cluster de incidente

4 MODELOS

O QUE ESTOURA

Risco de OLA

- Probabilidade de violação de KPI por incidente

1 MODELO

QUANTO DEMORA

Duração do atendimento

- Tempo previsto de resolução por incidente

1 MODELO

O QUE QUEBRA

Padrões de incidente

- K-means sobre atributos
- NLP sobre a descrição

2 MODELOS





Que tipo de trabalho chega

Cluster 0



CHAMADOS GERADOS POR
MONITORAMENTO

 **77.719**
chamados
(+60% do total)

 **100%**
gerado por
monitoramento

 **71%**
classificados
como P4 (baixa)

 **100%**
categoria
infra_monitoramento

Cluster 1



CHAMADOS OPERACIONAIS
GERAIS

 **31.494**
chamados
(25,7% do total)

 **49%** Manual
51% Monitoramento

 **71%**
classificados
como P3 (médio)

 Sem
Categoria
Dominante

Cluster 2



CHAMADOS
ESPECIALIZADOS

 **13.330**
chamados
(10,9% do total)

 **79%**
gerado por
monitoramento

 **29%**
classificados
como P2 (alta)

 Categorias
específicas
dominam



Previsão de Demanda

Geral

Algoritmo utilizado:
Gradient Boosting Regressor

D+1
(demanda para o dia seguinte)

MAPE 13.64% e MAE 106
Modelo **erra apenas 13,6% do volume previsto**
para o dia seguinte
Baseline: MAPE de **20%** e MAE de **164.28**

D+7
(demanda para semana seguinte)





MAPE 16.1% e MAE 128
Modelo **erra apenas 16,1% do volume previsto**
para o D+7
Baseline: MAPE de **20.8%** e MAE de **171.4**

Por Turno

Algoritmo utilizado:
Gradient Boosting Regressor

Geral

MAPE 22% e MAE 49.2
Modelo **erra apenas 22% do volume previsto**
para o dia seguinte
Baseline: MAPE de **31.5%** e MAE de **62**



Por Cluster

Ruído de Monitoramento

D+1 – persistência (MAE 99)
D+7 – persistência (MAE 110,5)

Operação Geral

D+1 – gradient boosting (MAE 27)
D+7 – gradient boosting (MAE 110,5)

Chamados Especializados

D+1 – gradient boosting (MAE 18)
D+7 – gradient boosting (MAE 17,3)

Risco de OLA e Duração

Os dois modelos que agem no incidente, não no volume

Previsão de Violação de KPI


Algoritmo utilizado:
Gradient Boosting Classifier

RECALL DE 0.92

- **92% dos casos de violação** do KPI são **identificados antecipadamente**
- Apenas 8% dos eventos de violação não recebem alerta


Threshold de 0.3 priorizando a identificação de riscos

ROC AUC DE 0,75




Previsão de Duração

Algoritmo utilizado:
Random Forest Regressor



70% das previsões ficam dentro de 30min da duração real



85% das previsões ficam dentro de 2h da duração real



Erro mediano de apenas 6 min (0.1h)

MAPE 24%


Baseline: MAPE de 37.02%

O que quebra, segundo a descrição do chamado

NLP sobre a descrição resumida: oito tipos de problema, cada um com um perfil próprio

Ruído Operacional


- Alertas operacionais e monitoramento
- +60% da base
- 70% monitoramento



P3
média

Falta de Memória Swap


- Falta de memória swap disponível
- 3% da base
- 100% monitoramento
- 95% "Sem Intervenção"



P4
baixa

Disk I/O overloaded


- Saturação de I/O de disco
- 8% da base
- 99% monitoramento
- 95% "Sem Intervenção"



P3
média
e P4 baixa

Sobrecarga de processamento


- Sobrecarga de processamento
- 3% da base
- 100% monitoramento
- 92% "Sem Intervenção"



P3
média

Capacidade de Armazenamento


- Alertas de capacidade de armazenamento
- 9,7% da base
- 100% monitoramento
- 40% "Sem Intervenção"



P4
baixa

Infraestrutura de Virtualização


- Infraestrutura de virtualização
- 2% da base
- 94% monitoramento
- 79% "Sem Intervenção"



P4
baixa

Apache e saturação de workers


- Apache e saturação de workers
- 2% da base
- 100% monitoramento
- 88% "Sem Intervenção"



P3
média


ICMP / Ping indisponível

- Indisponibilidade de servidores ou dispositivos
- 4% da base
- 100% monitoramento
- 60% "Sem Intervenção"



P2
alta

Arquitetura da Solução



PAINES


Alguns dos gráficos interessantes dos Paineis
Antes da demonstração da solução

Painel NOC


O NOC enxerga o risco antes do estouro

Fila do dia, incidentes em risco de violar o OLA e o que fugiu do normal.


Incidentes por prioridade e nível de risco de violar o OLA



Fila do dia: incidentes abertos vs resolvidos (09/12/2025)




Tipos de problema acima ou abaixo do normal hoje




Tipos de problema mais frequentes hoje

cluster_nlp



Tipo de trabalho

☐ Todos ☐ Cauda crítica ☐ Operação geral ☒ Ruído de monitoramento



INCIDENTES DO DIA

881

↑ 2,4% vs previsto

PREVISTOS NO DIA (D+1)

860

↑ 696 vs média hist.

INCIDENTES P1/P2 NO DIA

78

↑ criticidade elevada

EXIGIRAM INTERVENÇÃO HUMANA

126

↑ 755 fecharam sozinhos

QUASE VIOLAÇÕES (PROB > 75%)

83

↑ 9 em risco crítico (>90%)

VIOLAÇÕES SLA NO MÊS

18


↓ -3 vs mês anterior

Painel de Gestores


O gestor vê onde agir, não só o que aconteceu

Exposição ao risco por equipe, criticidade por problema e quanto do volume dá para eliminar.

Incidentes em risco de violar o OLA, por equipe





Prioridade dos chamados em cada tipo de problema




Quanto do volume dá para eliminar



Tipos de problema que estão crescendo (por mês)






% de cada tipo de problema que é ruído, operação ou crítico



Jornal de Turno

Nenhum incidente se perde na troca de turno

O que passa aberto, com quanto prazo e para qual equipe — recortado pelo turno selecionado.



🕒 # Selecione o turno

Madrugada

Manhã

Tarde

Noite

A resposta sem depender de quem sabe SQL

Gemini no Vertex AI sobre os mesmos dados do BigQuery

Consulta em linguagem natural

Digite sua pesquisa em linguagem natural:

me mostre os top 5 itens de configuração com mais incidentes

Pesquisar

Pergunta atual: "me mostre os top 5 itens de configuração com mais incidentes"

Ver consulta SQL gerada pela IA

```
SELECT Item_de_configuracao, COUNT(Numero) AS Total_Incidentes FROM incidentes WHERE Item_d
```

Resultado da Consulta

	Item_de_configuracao	Total_Incidentes
0	IC00014	6069
1	IC00019	4435
2	IC00008	4196
3	IC00349	3271
4	IC00002	3119

Linguagem natural → Consultas SQL

Assistente de IA

IA Generativa para Gestores

Assistente executivo com Google Gemini para análises de tendência, dimensionamento e tomada de decisão estratégica. O histórico desta conversa fica salvo durante toda a sessão atual.

Olá, gestor. Sou o Assistente Estratégico do Predict Ops. Como posso apoiar suas decisões de planejamento e mitigação de riscos operacionais hoje?

Consultas estratégicas recomendadas:

Previsão para a próxima semana

Equipes com risco de violação de SLA

Recomendações para redução de riscos

Quais recomendações práticas e preventivas a plataforma sugere para reduzir a pressão operacional no time de suporte?

Com base nos dados consultados, identificamos um ponto crítico que exige atenção imediata para reduzir a pressão operacional e mitigar riscos de SLA.

Análise dos Dados Consultados:

A consulta aos incidentes com KPI violado revela uma concentração significativa de problemas:

- Cluster 0: Responsável por 237 incidentes com KPI violado.
- Cluster 7: Registrou 6 incidentes com KPI violado.
- Cluster 4: Registrou 5 incidentes com KPI violado.

É evidente que o **Cluster 0 é o principal vetor de violações de SLA**, respondendo por aproximadamente 95% dos incidentes com KPI violado identificados nesta análise (237 de 248). Isso indica que a maior parte da pressão operacional decorrente de falhas de SLA está concentrada neste segmento.

Recomendações Práticas e Preventivas:

Chatbot para dúvidas gerais

DEMONSTRAÇÃO DA SOLUÇÃO

[Link Demo](#)

Quanto custa e o que retorna?

Custo mensal de infraestrutura

Cenário: 24 mil incidentes/mês, 20 usuários, pipeline a cada 3h

Cloud Run (aplicação)	1 vCPU, 2 GiB, sempre ativa	US\$ 60
Cloud Run Job (pipeline)	a cada 3 h (8×/dia), ~3 min	US\$ 2
Cloud Run Job (retreino)	1×/dia, ~15 min	US\$ 1.6
BigQuery	1 GB armazenado, ~100 GB consultados	US\$ 0*
Cloud Storage	bronze + silver, ~5 GB	US\$ 0,1
Vertex AI (Gemini Flash)	~1.000 interações/mês	US\$ 4
Scheduler + Artifact Registry	agendamento e imagens	US\$ 0,5

Total **≈ US\$ 68/mês · R\$ 365/mês**

Retorno esperado

- Volume real de out a dez/2025; taxa de corte é premissa
- 71.862 incidentes (apenas 13% exigem intervenção humana)

3.137

chamados/mês exigem uma pessoa
(13% do volume)

1.280

deles são duplicados (tem pai) ou
saturação == 41% dos 3k dão trabalho

192h

poupadas com a redução de 30% dos
chamados, considerando 30 minutos de
trabalho por incidente

Até 192h/mês de capacidade operacional liberada
≈ R\$ 11,5 mil/mês em valor potencial

Premissas: 30 min de analista por chamado e R\$ 60/hora.
Eliminar 20% = 128h (R\$7680); 50% = 320h (R\$19200)

* dentro do nível gratuito do BigQuery (10 GB e 1 TiB consultados/mês). Piloto sob demanda: US\$ 13/mês. Escala 10×: US\$ 290/mês.



O que este projeto provou

O PredictOps 360 não promete acabar com incidente. Promete que a operação pare de descobrir o problema depois que ele aconteceu.

O dado já continha a resposta

Transformamos grandes volumes de incidentes em previsões, padrões e insights para a operação.

Antecipar é melhor que reagir

Identificamos riscos e tendências antes que eles impactem os indicadores e as equipes.


Previsão sem tela não vira decisão

Painéis, consultas inteligentes e recomendações colocam a informação certa na hora certa.

Baixo custo, alto retorno

Uma solução acessível, escalável e capaz de gerar ganhos reais para a operação.





**ANTECIPE O FUTURO,
PROTEJA O PRESENTE**

Obrigado pela atenção!

