




ANTECIPE O FUTURO, PROTEJA O PRESENTE



INTEGRANTES

**Angelo
Rabello**

RM564338

**Isabella
Heder**

RM561300

**João
Daleessio**

RM561050



**Milena
Oliveira**

RM558913

**Paulo
Luchini**

RM561477






Proposta da Solução

ANTECIPE O FUTURO, PROTEJA O PRESENTE



O PredictOps é uma **plataforma de inteligência operacional** que utiliza **Inteligência Artificial, Machine Learning e Analytics** Avançado para transformar dados históricos de incidentes em **previsões, insights e recomendações acionáveis**. Ao centralizar **análise preditiva, monitoramento operacional** e acesso inteligente à informação, a solução capacita equipes técnicas e gestores a tomarem decisões mais rápidas, proativas e orientadas por dados, aumentando a eficiência operacional e reduzindo riscos ao negócio.

Público Alvo da Solução




EQUIPE DE TI & OPS

- **Usuários diretos da solução**
- Precisam de previsões confiáveis para antecipar incidentes
- Buscam melhor organização e redução da sobrecarga



GESTORES

- **Responsáveis por indicadores de desempenho**
- Necessitam relatórios e insights estratégicos
- Apoio na tomada de decisão e cumprimento de OLA



CLIENTES

- Não utilizam a plataforma diretamente
- **São afetados pela qualidade da operação interna**
- Percebem maior estabilidade e confiança nos serviços

Funcionalidades da Solução

PAINEL NOC

Painel operacional: Para monitoramento em tempo real de incidentes, OLAs e alertas críticos

Usuário: Operadores

JORNAL DE TURNO

Painel de turno: Para monitoramento dos incidentes, alertas e métricas durante o turno específico.

Usuário: Gestores e Operadores

PAINEL GERENCIAL

Painel de negócios: Para decisão estratégica baseada em incidentes, times, demandas e riscos.

Usuário: Gestores

CONSULTAS SQL

Linguagem Natural: Permite consultar a base histórica de incidentes em linguagem natural, convertendo perguntas em queries SQL

Usuário: Gestores e Operadores

CHATBOT

IA Assistente: Para esclarecer dúvidas em tempo real, investiga reincidências operacionais e orienta decisões com análises preditivas de OLA

Usuário: Gestores e Operadores



Motor analítico

São oito modelos publicados, agrupados pela pergunta de negócio que respondem

QUANTO VEM

Previsão da Demanda

- D+1 (dia seguinte)
- D+7 (semana seguinte)
- Por turno (4 janelas)
- Por cluster de incidente

4 MODELOS

O QUE ESTOURA

Risco de OLA

- Probabilidade de violação de KPI por incidente

1 MODELO

QUANTO DEMORA

Duração do atendimento

- Tempo previsto de resolução por incidente

1 MODELO

O QUE QUEBRA

Padrões de incidente

- K-means sobre atributos
- NLP sobre a descrição

2 MODELOS



Previsão de Demanda

Modelo D+1

Algoritmo Utilizado:

Gradient Boosting Regressor

Métricas Avaliativas Obtidas:



MAPE: 13.64%

Modelo **erra apenas 13,6% do volume previsto** para o dia seguinte



MAE: 106.19

Baseline: MAPE de 20% e MAE de 164.28

Modelo D+7

Algoritmo Utilizado:

Gradient Boosting Regressor

Métricas Avaliativas Obtidas:



MAPE: 16.15%

Modelo **erra apenas 16,1% do volume previsto** para o D+7



MAE: 128.59

Baseline: MAPE de 20.8% e MAE de 171.4

Antecipação de Violações de KPI

Resultados Obtidos

Algoritmo Utilizado:

Gradient Boosting Classifier

Threshold de 0.3 priorizando a identificação de riscos


RECALL DE 0.92

- **92% dos casos de violação** do KPI são **identificados antecipadamente**
- Apenas 8% dos eventos de violação não recebem alerta

ROC AUC de 0,75

- Capacidade de Distinção: Boa separação entre classes

8%
NÃO
IDENTIFICADAS



Threshold 0.5:

- Acurácia 0.83
- Recall 0.68
- Roc Auc 0.75

Threshold 0.4:

- Acurácia 0.7
- Recall 0.86
- Roc Auc 0.78

Features utilizadas:

Prioridade, Produto, Categoria, Subcategoria, Grupo designado, Item de configuração, Aberto por, tem_produto, tem_categoria, tem_subcategoria, tem_item_config, mes, tem_AM, hora_abertura, dia_semana e fim_de_semana.

Que tipo de trabalho chega

Cluster 0



CHAMADOS GERADOS POR
MONITORAMENTO



77.719

chamados
(+60% do total)



100%

gerado por
monitoramento

71%

classificados
como P4 (baixa)



100%

categoria
infra_monitoramento

PREVISÃO DE VOLUME:

D+1 - persistência (MAE 99)

D+7 - persistência (MAE 110,5)

Cluster 1



CHAMADOS OPERACIONAIS
GERAIS



31.494

chamados
(25,7% do total)



49% Manual

51% Monitoramento



71%

classificados
como P3 (médio)




Sem
Categoria
Dominante

PREVISÃO DE VOLUME:

D+1 - gradient boosting (MAE 27)

D+7 - gradient boosting (MAE 110,5)

Cluster 2



CHAMADOS
ESPECIALIZADOS



13.330

chamados
(10,9% do total)



79%

gerado por
monitoramento



29%

classificados
como P2 (alta)



Categorias
específicas
dominam

PREVISÃO DE VOLUME:

D+1 - gradient boosting (MAE 18)

D+7 - gradient boosting (MAE 17,3)

Previsão de Demanda por Turno

Modelo Global

Algoritmo Utilizado:

Gradient Boosting Regressor

Métricas Avaliativas Gerais:



MAPE: 22.32%

Modelo **erra apenas 22% do volume previsto** para o turno seguinte




MAE: 49.25

Baseline: MAPE de **31.59%** e MAE de **62**

Desempenho por Turno


Turno:

MADRUGADA (0h - 6h)




Turno:

NOITE (18h - 24h)




Turno:

MANHÃ (6h - 12h)



Turno:

TARDE (12h - 18h)




Previsão Inteligente da Duração dos Incidentes

Resultados Obtidos


Algoritmo Utilizado:

Random Forest Regressor

MAPE DE 24,14%



70% das previsões ficam dentro de 30min da duração real




85% das previsões ficam dentro de 2h da duração real



Erro mediano de apenas 6 min
(0.1h)

Baseline: MAPE de 37%

Impacto para a operação:



Maior previsibilidade para equipes



Melhor previsão de cumprimento de OLA



Apoio ao planejamento operacional em tempo real


Features utilizadas:

'Produto', 'Categoria', 'Grupo designado',
'prioridade_num', 'hora_aberto', 'fim_semana',
'fora_comercial', 'monitoramento', 'tem_pai'

Cluster NLP (Descrição)


Ruído Operacional

- Alertas operacionais e monitoramento
- +60% da base
- 70% monitoramento
- Ex: Application Monitoring, Timeouts, health check, alarm application monitoring




Falta de Memória Swap

- Falta de memória swap disponível
- 3% da base
- 100% monitoramento
- 95% "Sem Intervenção"
- Keywords: swap, swap memory server




Disk I/O overloaded

- Saturação de I/O de disco
- 8% da base
- 99% monitoramento
- 95% "Sem Intervenção"
- Keywords: overloaded




Sobrecarga de processamento

- Sobrecarga de processamento
- 3% da base
- 100% monitoramento
- 92% "Sem Intervenção"
- Keywords: IOWAIT, CPU, too




Capacidade de Armazenamento

- Alertas de capacidade de armazenamento
- 9,7% da base
- 100% monitoramento
- 40% "Sem Intervenção"
- Keywords: volume, less than, disk




Infraestrutura de Virtualização

- Infraestrutura de virtualização
- 2% da base
- 94% monitoramento
- 79% "Sem Intervenção"
- Keywords: hypervisor, erro, servidores




Apache e saturação de workers

- Apache e saturação de workers
- 2% da base
- 100% monitoramento
- 88% "Sem Intervenção"
- Keywords: busy workers, apache





ICMP / Ping indisponível

- Indisponibilidade de servidores ou dispositivos
- 4% da base
- 100% monitoramento
- 60% "Sem Intervenção"
- Keywords: icmp ping



Arquitetura da Solução



Ferramentas/Tecnologias	Justificativa do uso da Tecnologia na Solução
	Utilizado como fonte inicial dos dados, permitindo a disponibilização e organização dos registros de incidentes de forma simples e estruturada.
	Utilizado como Data Lake para armazenamento dos dados em diferentes camadas, mantendo os dados brutos na Bronze e os dados tratados e preparados para análise na Silver .
	Responsável pela execução automatizada dos scripts Python, permitindo orquestrar as etapas de tratamento, processamento e geração dos resultados de Machine Learning sem necessidade de manter servidores ativos.
	Utilizado para programar a execução periódica do pipeline, automatizando a atualização dos dados e das previsões.
	Principal linguagem utilizada no projeto, permitindo realizar limpeza e transformação dos dados, feature engineering, análises, clusterização, treinamento dos modelos e geração das previsões.
	Utilizado como camada Gold , centralizando os dados tratados, previsões e resultados dos modelos em tabelas estruturadas, facilitando consultas analíticas e o consumo pelas aplicações.
	Aplicado para transformar os dados históricos em previsões e insights, permitindo antecipar volume de incidentes, riscos de SLA, duração dos atendimentos e outros indicadores operacionais.
	Utilizados para analisar as descrições dos incidentes e identificar automaticamente grupos de problemas com características semelhantes, apoiando a descoberta de padrões operacionais.
	Utilizado para construção da aplicação de consumo, disponibilizando dashboards e análises de forma interativa para diferentes perfis de usuários, como operação, NOC e gestão.
	Utilizado para permitir interação com os dados por linguagem natural, interpretando perguntas dos usuários e auxiliando na geração de consultas e análise dos resultados.
	Utilizado como camada de memória da aplicação, armazenando informações relacionadas às consultas e ao contexto necessário para proporcionar uma experiência conversacional mais consistente.

Evidências Google Cloud

predictops-challenge-2026 / Datasets /

☆ predictops_gold

Visão geral Detalhes Insights

Tabelas Gráficos Modelos Rotinas

Filtro Insira o nome ou o valor da propriedade

Código da tabela	Tipo
cluster_nlp	Tabela
clusters_incidentes	Tabela
incidentes	Tabela
metricas_previsao_por_cluster	Tabela
previsao_d1	Tabela
previsao_d1_por_cluster	Tabela
previsao_d7	Tabela
previsao_d7_por_cluster	Tabela
previsao_duracao	Tabela
previsao_sla	Tabela
previsao_turno	Tabela

Google Cloud predictops-challenge-2026 Pesquisar (0) n

Detalhes do job ▶ Execução ▶ Ler e editar a

predictops-job job Região: southamerica-east1 Última at

Histórico Observabilidade Gatilhos YAML

Filtro Filtrar histórico


ID da execução	Data/hora de criação ↓
predictops-job-pgqkg	1 de set. de 2026, 22:08:47

Task 0 logs

Registros Gravidade Padrão Filtro Pesquisar todos os campos e valores

Mostrando registros para o horário especificado na consulta. Para acessar mais resultados, atualize sua consulta.


Gravidade	Hora	Resumo
>	2026-09-01 22:09:55.553 BRT	Linhas: ((122543, 19),)
>	2026-09-01 22:09:55.553 BRT	Colunas: 19
>	2026-09-01 22:09:55.553 BRT	Silver gerada com sucesso!
>	2026-09-01 22:09:55.553 BRT	gs://predictops-silver/incidentes/incidentes_tratados.parquet
>	2026-09-01 22:10:02.619 BRT	Lendo Silver...
>	2026-09-01 22:10:02.619 BRT	(122543, 28)
>	2026-09-01 22:10:02.619 BRT	Linhas para modelagem: 328
>	2026-09-01 22:10:02.620 BRT	Treinando D+1
>	2026-09-01 22:10:02.620 BRT	MODELO D+1
>	2026-09-01 22:10:02.620 BRT	MAE: 106.16048479581187
>	2026-09-01 22:10:02.620 BRT	RMSE: 142.31539629278473
>	2026-09-01 22:10:02.620 BRT	R²: 0.37498421731306764
>	2026-09-01 22:10:02.620 BRT	Treinando D+7
>	2026-09-01 22:10:02.620 BRT	MODELO D+7
>	2026-09-01 22:10:02.620 BRT	MAE: 128.59880669498216





PAINEIS

Alguns dos gráficos interessantes dos Paineis
Antes da demonstração da solução




Painel NOC


O NOC enxerga o risco antes do estouro

Fila do dia, incidentes em risco de violar o OLA e o que fugiu do normal.


Incidentes por prioridade e nível de risco de violar o OLA



Fila do dia: incidentes abertos vs resolvidos (09/12/2025)




Tipos de problema acima ou abaixo do normal hoje




Tipos de problema mais frequentes hoje

cluster_nlp



Tipo de trabalho

☐ Todos ☐ Cauda crítica ☐ Operação geral ☒ Ruído de monitoramento



INCIDENTES DO DIA

881

↑ 2,4% vs previsto

PREVISTOS NO DIA (D+1)

860

↑ 696 vs média hist.

INCIDENTES P1/P2 NO DIA

78

↑ criticidade elevada

EXIGIRAM INTERVENÇÃO HUMANA

126

↑ 755 fecharam sozinhos

QUASE VIOLAÇÕES (PROB > 75%)

83

↑ 9 em risco crítico (>90%)

VIOLAÇÕES SLA NO MÊS

18


↓ -3 vs mês anterior

Painel de Gestores


O gestor vê onde agir, não só o que aconteceu

Exposição ao risco por equipe, criticidade por problema e quanto do volume dá para eliminar.


Incidentes em risco de violar o OLA, por equipe





Prioridade dos chamados em cada tipo de problema




Quanto do volume dá para eliminar



Tipos de problema que estão crescendo (por mês)



% de cada tipo de problema que é ruído, operação ou crítico



Jornal de Turno


Nenhum incidente se perde na troca de turno

O que passa aberto, com quanto prazo e para qual equipe — recortado pelo turno selecionado.


Incidentes ainda abertos às 00h, por equipe e prazo




Tipos de problema acima do normal neste turno



Equipes com maior risco de violar o OLA



Equipes com mais incidentes que o normal neste turno



Indicadores do turno

Tarde (12h-18h)

PREVISÃO PARA O TURNO

198

↑ 15,9% vs histórico

REGISTRADOS NO TURNO

214

↑ 8,1% vs previsão

CRÍTICOS P1/P2 NO TURNO

28

EM RISCO ELEVADO (>75%)

83

↑ 9 em risco crítico (>...)

Selecione o turno

Madrugada

Manhã

Tarde

Noite

A resposta sem depender de quem sabe SQL

Gemini no Vertex AI sobre os mesmos dados do BigQuery

Consulta em linguagem natural

Digite sua pesquisa em linguagem natural:

Pesquisar

me mostre os top 5 itens de configuração com mais incidentes

Pergunta atual: "me mostre os top 5 itens de configuração com mais incidentes"

Ver consulta SQL gerada pela IA

```
SELECT Item_de_configuracao, COUNT(Numero) AS Total_Incidentes FROM incidentes WHERE Item_d
```

Resultado da Consulta

	Item_de_configuracao	Total_Incidentes
0	IC00014	6069
1	IC00019	4435
2	IC00008	4196
3	IC00349	3271
4	IC00002	3119

Linguagem natural → Consultas SQL

Assistente de IA

IA Generativa para Gestores

Assistente executivo com Google Gemini para análises de tendência, dimensionamento e tomada de decisão estratégica. O histórico desta conversa fica salvo durante toda a sessão atual.

Olá, gestor. Sou o Assistente Estratégico do Predict Ops. Como posso apoiar suas decisões de planejamento e mitigação de riscos operacionais hoje?

Consultas estratégicas recomendadas:

Previsão para a próxima semana

Equipes com risco de violação de SLA

Recomendações para redução de riscos

Quais recomendações práticas e preventivas a plataforma sugere para reduzir a pressão operacional no time de suporte?

Com base nos dados consultados, identificamos um ponto crítico que exige atenção imediata para reduzir a pressão operacional e mitigar riscos de SLA.

Análise dos Dados Consultados:

A consulta aos incidentes com KPI violado revela uma concentração significativa de problemas:

- Cluster 0: Responsável por 237 incidentes com KPI violado.
- Cluster 7: Registrou 6 incidentes com KPI violado.
- Cluster 4: Registrou 5 incidentes com KPI violado.

É evidente que o Cluster 0 é o principal vetor de violações de SLA, respondendo por aproximadamente 95% dos incidentes com KPI violado identificados nesta análise (237 de 248). Isso indica que a maior parte da pressão operacional decorrente de falhas de SLA está concentrada neste segmento.

Chatbot para dúvidas gerais

Quanto custa e o que retorna?

Custo mensal de infraestrutura

Cenário: 24 mil incidentes/mês, 20 usuários, pipeline a cada 3h

Cloud Run (aplicação)	1 vCPU, 2 GiB, sempre ativa	US\$ 60
Cloud Run Job (pipeline)	a cada 3 h (8×/dia), ~3 min	US\$ 2
Cloud Run Job (retreino)	1×/dia, ~15 min	US\$ 1.6
BigQuery	1 GB armazenado, ~100 GB consultados	US\$ 0*
Cloud Storage	bronze + silver, ~5 GB	US\$ 0,1
Vertex AI (Gemini Flash)	~1.000 interações/mês	US\$ 4
Scheduler + Artifact Registry	agendamento e imagens	US\$ 0,5

Total **≈ US\$ 68/mês · R\$ 365/mês**

Retorno esperado

- Volume real de out a dez/2025; taxa de corte é premissa
- 71.862 incidentes (apenas 13% exigem intervenção humana)

3.137

chamados/mês exigem uma pessoa (13% do volume)

1.280

deles são duplicados (tem pai) ou saturação == 41% dos 3k dão trabalho

192h

poupadas com a redução de 30% dos chamados, considerando 30 minutos de trabalho por incidente

Até 192h/mês de capacidade operacional liberada
≈ R\$ 11,5 mil/mês em valor potencial

Premissas: 30 min de analista por chamado e R\$ 60/hora.
Eliminar 20% = 128h (R\$7680); 50% = 320h (R\$19200)

* dentro do nível gratuito do BigQuery (10 GB e 1 TiB consultados/mês). Piloto sob demanda: US\$ 13/mês. Escala 10×: US\$ 290/mês.



O que este projeto provou

O PredictOps 360 não promete acabar com incidente. Promete que a operação pare de descobrir o problema depois que ele aconteceu.

O dado já continha a resposta

Transformamos grandes volumes de incidentes em previsões, padrões e insights para a operação.

Antecipar é melhor que reagir

Identificamos riscos e tendências antes que eles impactem os indicadores e as equipes.


Previsão sem tela não vira decisão

Painéis, consultas inteligentes e recomendações colocam a informação certa na hora certa.

Baixo custo, alto retorno

Uma solução acessível, escalável e capaz de gerar ganhos reais para a operação.





Vídeo Pitch

Link Github

Vídeo Demo

Link Demo





EXTRAS

informações técnicas
e mais detalhadas



Como o baseline é calculado?

Modelo

Baseline Utilizado

Volume D+1

Repete o valor do dia anterior

Volume D+7

Repete o mesmo dia da semana anterior

Volume por Turno

Repete o valor do mesmo turno do dia anterior

Volume por Regime

Hoje, ontem e média de sete dias

Duração

DummyRegressor(strategy='mean')

Modelo D+1 e D+7

DADOS E FEATURES

Unidade: 1 linha por dia

- lag_1: volume de ontem
- lag_7: mesmo dia da semana anterior
- media_7d: média móvel de 7 dias
- tem_AM: % do dia com alerta Application Monitoring
- mes
- Alvos: target_d1 (t+1) e target_d7 (t+7)

Split

- Temporal, 80/20: os últimos 20% da série são o teste

ALGORITMO E DECISÕES

GradientBoostingRegressor

- D+1: n_estimators=100, max_depth=4, learning_rate=0.03, random_state=42
- D+7: n_estimators=100, max_depth=2, learning_rate=0.05, random_state=42

Decisões de preparo

- Sem scaler
- 11 combinações de features testadas
- 5 algoritmos comparados: GB venceu XGB, RF e ExtraTrees

BASELINE E RESULTADO

Baseline:

baseline = test['lag_1']

13,6% → MAPE D+1 (baseline 20,0%)

16,1% → MAPE D+7 (baseline 20,8%)

Risco de violação de OLA

DADOS E FEATURES

Unidade: 1 linha por incidente elegível

- Filtro: só 'Entrou para KPI? = SIM'
- Prioridade, Produto, Categoria, Subcategoria
- Grupo designado, Item de configuração, Aberto por
- hora_abertura, dia_semana, fim_de_semana
- Removidas por data leak: Resolvido, Encerrado, Duração,
- Código de fechamento, Solução, Status, tem_resolucao, tem_CF

Split 80/20, get_dummies, stratify

ALGORITMO E DECISÕES

GradientBoostingClassifier

- n_estimators=300, learning_rate=0.05, max_depth=3, random_state=42

Desbalanceamento e threshold

- RandomUnderSampler no TREINO; teste fica desbalanceado de propósito
- Thresholds testados: 0,2 • 0,3 • 0,4 → escolhido 0,3
- 4 algoritmos comparados: LogReg, RF, XGBoost e GB
- Sem scaler

RESULTADO

- **0,92 → recall**
- **0,75 → ROC AUC**
- **0,58 → acurácia**

Threshold 0.4:

- Acurácia 0.7
- Recall 0.86
- Roc Auc 0.78

Threshold 0.5:

- Acurácia 0.83
- Recall 0.68
- Roc Auc 0.75

Previsão de duração

DADOS E FEATURES

Unidade: 1 linha por incidente

- Categóricas: Produto, Categoria, Grupo designado
- prioridade_num: 1 Crítica a 5 Muito Baixa
- hora_aberto, fim_semana, fora_comercial (<8h ou ≥18h)
- monitoramento: aberto por automação
- tem_pai: é filho de outro incidente

Split 80/20, get_dummies nas 3 categóricas

ALGORITMO E DECISÕES

RandomForestRegressor

- n_estimators=200, n_jobs=-1,
- random_state=42

Target: $y = \text{np.log1p}(\text{Duração})$

Volta: $\text{np.expml}(\text{pred}) / 3600$

Por que log1p na target

- A duração tem cauda longuíssima (outliers)
- O log comprime a cauda e o erro passa a ser proporcional, não absoluto
- Métricas de negócio recalculadas em horas, depois do expml

BASELINE E RESULTADO

Baseline

DummyRegressor(strategy='mean')

- 70% → das previsões a menos de 30 min
- 85% → dentro de 2 horas
- 6 min → erro mediano
- 24% → MAPE (baseline 37,02%)

5 modelos comparados: Dummy, LinearRegression, RandomForest, GradientBoosting e HistGB.

Clusterização de incidentes (K-Means)

DADOS E FEATURES

Unidade: 1 linha por incidente

- Prioridade_cluster, Produto, Categoria_cluster
- Subcategoria_cluster, Grupo designado
- Item_config_cluster, Aberto por
- hora_abertura, dia_semana, fim_de_semana, mes, tem_AM
- '1 - Crítica' (1 ocorrência) agrupada com '2 - Alta'

Split

- Não supervisionado — sem treino/teste
- Amostra de 15.000 registros só para escolher o k

ALGORITMO E DECISÕES

KMeans (k = 3)

- Elbow: k entre 2 e 10
- Silhouette final: 0,4648

Seleção de apenas os IC top 100, Categoria e Subcategoria top 30

- Sem isso, o one-hot geraria centenas de colunas quase vazias

Standard Scaler e One-hot nas colunas categóricas

RESULTADO

- **77.719 → Ruído de monitoramento (63%)**
- **31.494 → Operação geral (26%)**
- **13.330 → Cauda crítica (11%)**
- **0,4648 → Silhouette em k=3**

Clusterização de incidentes (NLP)

DADOS E FEATURES

Entrada: Número + Descrição resumida

- Texto limpo: minúsculas, sem acento, só letras
- Remove IDs, URLs e e-mails
- Remove palavras com até 2 letras
- Stopwords em PT e EN + lista operacional própria

Split

- Não supervisionado
- Amostra de 10.000 registros para calcular as métricas

ALGORITMO E DECISÕES

TF-IDF + MiniBatchKMeans

- `n_clusters=k`, `random_state=42`, `n_init=10`, `batch_size=2048`
- Vetorizadores testados: word 1-2, word 1-3 e char_wb 3-5
- `k = 4, 8, 10, 12`

Como o vencedor foi escolhido

- Avaliamos Silhouette, Davies-Bouldin e Calinski-Harabasz
- Os scores foram normalizados e combinados
- Venceu a configuração com melhor score geral
- Métricas calculadas com TruncatedSVD (100 componentes)

RESULTADO

- **8 → tipos de problema**
- **95% → P2 em Indisponibilidade**
- **13% → P2 na média da base**
- **4% → do volume é Indisponibilidade**

Previsão de volume por turno

DADOS E FEATURES

Unidade: 1 linha por dia × turno

- turno_code — Madrugada 0, Manhã 1, Tarde 2, Noite 3
- dow, mes, is_weekend
- lag_1, lag_7, lag_14 — sempre do MESMO turno
- media_7d, media_14d — do mesmo turno, com shift(1)
- features_plus = base + media_14d + lag_14

Split

- Temporal, 80/20
- Série completada com zero nas combinações sem incidente

ALGORITMO E DECISÕES

GradientBoosting

- n_estimators=200, max_depth=2, learning_rate=0.03, loss='huber', random_state=42

Turnos: 0-6h, 6-12h, 12-18h, 18-24h

Decisões de preparo

- Lags calculados dentro do turno, não entre turnos consecutivos
- shift(1) antes do rolling — sem olhar o próprio dia
- Previsão cortada em zero: np.maximum(0, pred)
- MAPE ignora dias de valor zero (evita divisão por zero)
- 5 modelos comparados

BASELINE E RESULTADO

Baseline:

baseline = test['lag_1']

- **22,0% → MAPE do modelo**
- **31,5% → MAPE do baseline**
- **49,2 → MAE (baseline 62)**
- **21-24% → MAPE por turno**

Previsão de volume por regime

DADOS E FEATURES

Unidade: 1 linha por dia x regime

- lag_1, lag_7, media_7d
- tem_AM, mes, dia_semana
- Mesmas features nos três regimes — o que muda é o modelo escolhido
- Calendário completo: dia sem incidente vira zero, não NaN

Split

- Treino → validação rolling-origin → teste cego (20%)
- 4 janelas de 30 dias, retreino a cada janela
- Janela com menos de 60 dias de treino é descartada

ALGORITMO E DECISÕES

9 candidatos por regime

- Ridge, GradientBoosting, GB_huber, HistGB, RandomForest
 - Naive_hoje, Naive_lag_1, Naive_media_7d
 - Ensemble (média do melhor ML com o melhor ingênuo)

Campeão de cada regime (D+1)

- Ruído de monitoramento → Naive_hoje (persistência venceu)
- Operação geral → GB_huber, 38,8% melhor que o ingênuo
- Cauda crítica → RandomForest, 27,6% melhor
- O campeão é eleito na validação; o teste só é tocado depois


BASELINE E RESULTADO

Baseline:

3 ingênuos como candidatos

Aqui o baseline não é referência externa: ele disputa de verdade. Ele ganhou nas opções de monitoramento (e ficou).

Para as opções mais específicas (operação geral e especializada) o ML ganhou e ficou.



**ANTECIPE O FUTURO,
PROTEJA O PRESENTE**

Obrigado pela atenção!

